



1. EDA

Имеем исходные данные размерности (1001, 213), 32 дубликата и 36 пропусков.

Распределение таргетов



Видим сильную большую плотность таргетов около нуля с довольно длинными хвостами. Посмотрим на их логарифмы:



Статистики для всех 6 распределений:

	Исходные таргеты			Log1p		
	mean	std	skew	mean	std	skew
IC50	222.81	402.17	3.67	3.98	1.86	-0.03
CC50	589.11	642.87	1.97	5.57	1.59	-0.91
SI	72.51	684.48	18.01	2.04	1.46	1.43

Данные стали несколько более человеческими, для IC50 видим почти нулевой skew, для всех трех метрик более естественное (для неотрицательных распределений) соотношение mean и std.

Для IC50 преобразование подходит хорошо, для двух других метрик делает лучше, но не идеальное. Это потенциальное место для улучшения: подобрать более подходящее преобразование данных для этих таргетов.

Дальше работаю с логарифмами таргетов.

Пропуски и дубликаты: дубликаты убираю вовсе (мало новых данных, а для линейных моделей они создают мультиколлинеарность → плохо обращаются матрицы), пропуски заполняю медианой по признаку (их относительно мало, вроде так должно быть адекватно).


Размер данных стал: (969, 216)

Теперь переходим к анализу признаков: надо проверить константность, скорелированность между собой и с таргетами (первые два вида – это опять про мультиколлинеарность, последний – это потенциальный data leak).

34 признака убрал из-за низкой дисперсии (порог в 0.01), ещё 33 убрал как скорелированные (корреляция > 0.95) с какими-то другими (оставил первый по номеру из таких пар).

После фильтрации осталось 143 признака. Корреляция с таргетами относительно низкая (< 0.2), подозреваю, что линейные модели будут работать довольно плохо.

Топ-15 признаков, скорелированных с логарифмом SI



2. Обучение

Для каждой задачи пробовал базовые модели с дефолтными параметрами:

- Линейная (Ridge для регрессий и логистическая регрессия для классификаций)
- RandomForest
- CatBoost

Для лучших запускал подбор гиперпараметров через Optuna (везде было по 25 итераций, данные для моделек не очень дружат с GPU, я справился запустить счет на ней, но все упиралось в пропускную способность памяти, было медленнее, чем параллельный перебор в 16 потоков на CPU. Потому это было довольно времязатратно и больше итераций не запускал. Потенциальное место для улучшения?).

Регрессии оптимизировал по уменьшению RMSE на кросс-валидации (5 фолдов), классификации по максимизации ROC-AUC на кроссвалидации (тоже 5 фолдов).

Для регрессий дополнительно сохранял R^2 , для классификаций – точность и $F1$.

Для базовых моделей стандартная ситуация была:

- линейная модель справлялась гораздо хуже, данные явно сильно нелинейны, хорошо согласуется с EDA
- CatBoost и RandomForest показывали похожие метрики:
 - для классификаций CatBoost чуть лучше на всех, кроме [CC50 > Median]
 - для регрессий леса чуть обогнали во всех трех случаях, но метрики очень близкие

Случайные леса чуть больше подстраиваются под конкретные данные, CatBoost чуть стабильнее на низких learning rate и у него потоньше настройки гиперпараметров.

Потому подбирал гиперпараметры везде для CatBoost:

- после настройки он везде обогнал леса для регрессий
- в случае [CC50 > Median] метрики случайного леса оказались строго лучше, чем у CatBoost после дообучения – только в этом месте суммарно лес оказался лучше.
- для регрессий везде получился довольно высокий прирост от подбора (R^2 вырос на 5–6%, сопровождается падением RMSE)
- для классификаций разница поменьше, замерный прирост только для [IC50 > Median] (+1.2% ROC-AUG и чуть выросшие точность и $F1$)
- для [SI > 8] и [SI > Median] видим близкие значения всех трех метрик, принципиально особо ничего не поменялось по сравнению с базовой моделью
- для [CC50 > Median] модель по этим метрикам вышла строго хуже случайного леса с прошлой итерации

3. Рекомендации по улучшению

- Увеличение числа и качества данных, добавление новых пространственных или графовых признаков
- В EDA остаётся пространство для более точного подбора преобразований и производных признаков
- С моделями стоит попробовать ансамбли, например, брать ансамбль CatBoost'a с RandomForest
- Можно точно расширить перебор через Optuna: расширить отрезки для параметров и увеличить число итераций
- Внедрить GroupKFold для валидации: проверить обобщающую способность моделей на новых группах химических соединений

4. Метрики и визуализация

Лучшие базовые модели для каждой задачи

Таргет	Тип	Лучшая модель	RMSE	R^2	ROC-AUC	Accuracy	F1
IC50	Регрессия	RandomForest	1.433	0.443	—	—	—
CC50	Регрессия	RandomForest	1.291	0.291	—	—	—
SI	Регрессия	RandomForest	1.372	0.167	—	—	—
IC50 > Median	Классификация	CatBoost	—	—	0.806	0.722	0.727
CC50 > Median	Классификация	RandomForest	—	—	0.845	0.753	0.747
SI > Median	Классификация	CatBoost	—	—	0.694	0.660	0.637
SI > 8	Классификация	CatBoost	—	—	0.756	0.737	0.579

Результаты базовых регрессий

Таргет	Модель	RMSE	R^2
IC50	Ridge	1.587528	0.316937
	RandomForest	1.433411	0.443123
	CatBoost	1.439453	0.438418
CC50	Ridge	1.334436	0.241973
	RandomForest	1.290553	0.291009
	CatBoost	1.308867	0.270744
SI	Ridge	1.503248	-0.000150
	RandomForest	1.371711	0.167222
	CatBoost	1.382432	0.154154

Результаты базовых классификаций

Задача	Модель	ROC-AUC	Accuracy	F1
IC50 > Median	LogisticRegression	0.430970	0.500000	0.666667
	RandomForest	0.793177	0.706186	0.701571
	CatBoost	0.805452	0.721649	0.727273
CC50 > Median	LogisticRegression	0.520512	0.500000	0.000000
	RandomForest	0.844457	0.752577	0.747368
	CatBoost	0.829153	0.742268	0.739583
SI > Median	LogisticRegression	0.589754	0.500000	0.000000
	RandomForest	0.674567	0.628866	0.604396
	CatBoost	0.693857	0.659794	0.637363
SI > 8	LogisticRegression	0.523594	0.644330	0.000000
	RandomForest	0.735942	0.726804	0.582677
	CatBoost	0.755652	0.737113	0.578512


Регрессия, результат подбора

Таргет	Старые данные		Новые данные	
	RMSE	R2	RMSE	R2
IC50	1.4334	0.4431	1.3502	0.5059
CC50	1.2906	0.2910	1.2376	0.3480
SI	1.3717	0.1672	1.3202	0.2286


Классификация, результат подбора

Таргет	Старые данные			Новые данные		
	ROC-AUC	Accuracy	F1	ROC-AUC	Accuracy	F1
IC50 > Median	0.8055	0.7216	0.7273	0.8172	0.7423	0.7475
CC50 > Median	0.8445	0.7526	0.7474	0.8363	0.7268	0.7254
SI > Median	0.6939	0.6598	0.6374	0.7011	0.6443	0.6102
SI > 8	0.7557	0.7371	0.5785	0.7475	0.7474	0.5739


Предсказания регрессий против реального таргета



ROC-кривые для классификаций



Важности признаков



Корреляции топ-20 признаков с лог-таргетами

